DEEP LEARNING 2026 · PROYECTO 3

Text-to-SQL en español con LoRA

Qwen2.5-Coder-1.5B-Instruct + adapter LoRA → consultas MySQL 8.4.10

Andrés Mazariegos · June Herrera
Universidad del Valle de Guatemala · octubre 2026

PROBLEMA

Dado un esquema y una pregunta, generar una consulta correcta

- **Entrada:** `SHOW CREATE TABLE` con `COMMENT` + pregunta en español
- **Salida:** una sola `SELECT` / `WITH … SELECT`
- MySQL 8.4.10 con `ONLY_FULL_GROUP_BY`
- ≤ 30 s por pregunta, determinista, Colab T4
- Se evalúa con bases y preguntas **que no conocemos**

Métrica: EX ponderada (exactitud por ejecución)

Nivel	Contenido	Peso
fácil	una tabla	1
media	JOIN, GROUP BY, HAVING	2
difícil	subconsultas, WITH, ventanas, fechas	3

Orden solo si se pide · números a 2 decimales · columna extra no penaliza

DATOS

10 158 pares válidos en MySQL 8.4.10

865 descartados, con motivo

8 828
Spider → MySQL, preguntas traducidas (opus-mt-en-es) protegiendo literales

1 330
pares generados con LLM sobre 18 esquemas propios con COMMENT y nombres abreviados

40
preguntas de validación en 2 esquemas no vistos (partición por esquema)

- Spider: se carga cada SQLite en MySQL, se transpila con `sqlglot` y se exige **mismo resultado** que en SQLite
- La mitad de las bases Spider recibe `COMMENT` en español
- Esquemas propios: ventanas, CTE, fechas, LEFT JOIN con ceros: lo que Spider no tiene

Descarte	Pares
resultado distinto a SQLite	408
error en MySQL (ONLY_FULL_GROUP_BY…)	191
prompt > 2 048 tokens	183
traducción alteró un literal	83

PROMPT Y SOLUCIÓN

Mismo prompt para baseline, entrenamiento y entrega

```
system: Eres un experto en bases de datos MySQL 8.4 …
        Responde únicamente con una consulta SQL …
user:   Esquema:
        CREATE TABLE `ord_srv` (
          `id_ord` int NOT NULL COMMENT 'Número de orden',
          `f_ing` date NOT NULL COMMENT 'Fecha de
ingreso',
          …
          FOREIGN KEY (`id_veh`) REFERENCES `veh`
(`id_veh`)
        ) COMMENT='Órdenes de servicio';
        Pregunta: ¿Cuántas órdenes …?
assistant: SELECT …
```

- `compactar_esquema`: quita ENGINE, CHARSET, índices secundarios; conserva tipos, COMMENT, PK, FK
- Decodificación voraz, una sola sentencia (primera SELECT/WITH, corte en ;)
- fp16 en T4: carga en 12 s y tarda 1–4 s por pregunta
- Pérdida solo sobre los tokens de la SQL

LORA: UN SOLO FACTOR

¿Dónde poner LoRA: solo atención o también MLP?

	A · `lora_attn`	B · `lora_all`
Módulos	q, k, v, o	+ gate, up, down
Parámetros entrenables	4.36 M (0.28 %)	18.46 M (1.18 %)
Tiempo (RTX 5070 Laptop)	77.7 min	92.7 min
VRAM máx	3.76 GB	4.11 GB
Loss dev final	0.144	**0.130**
EX ponderada	**0.388**	**0.450**

Hipótesis (antes de entrenar): B > A. Las MLP guardan los patrones de generación (dialecto, CTE, ventanas); la atención decide sobre todo *a qué columnas mirar*.

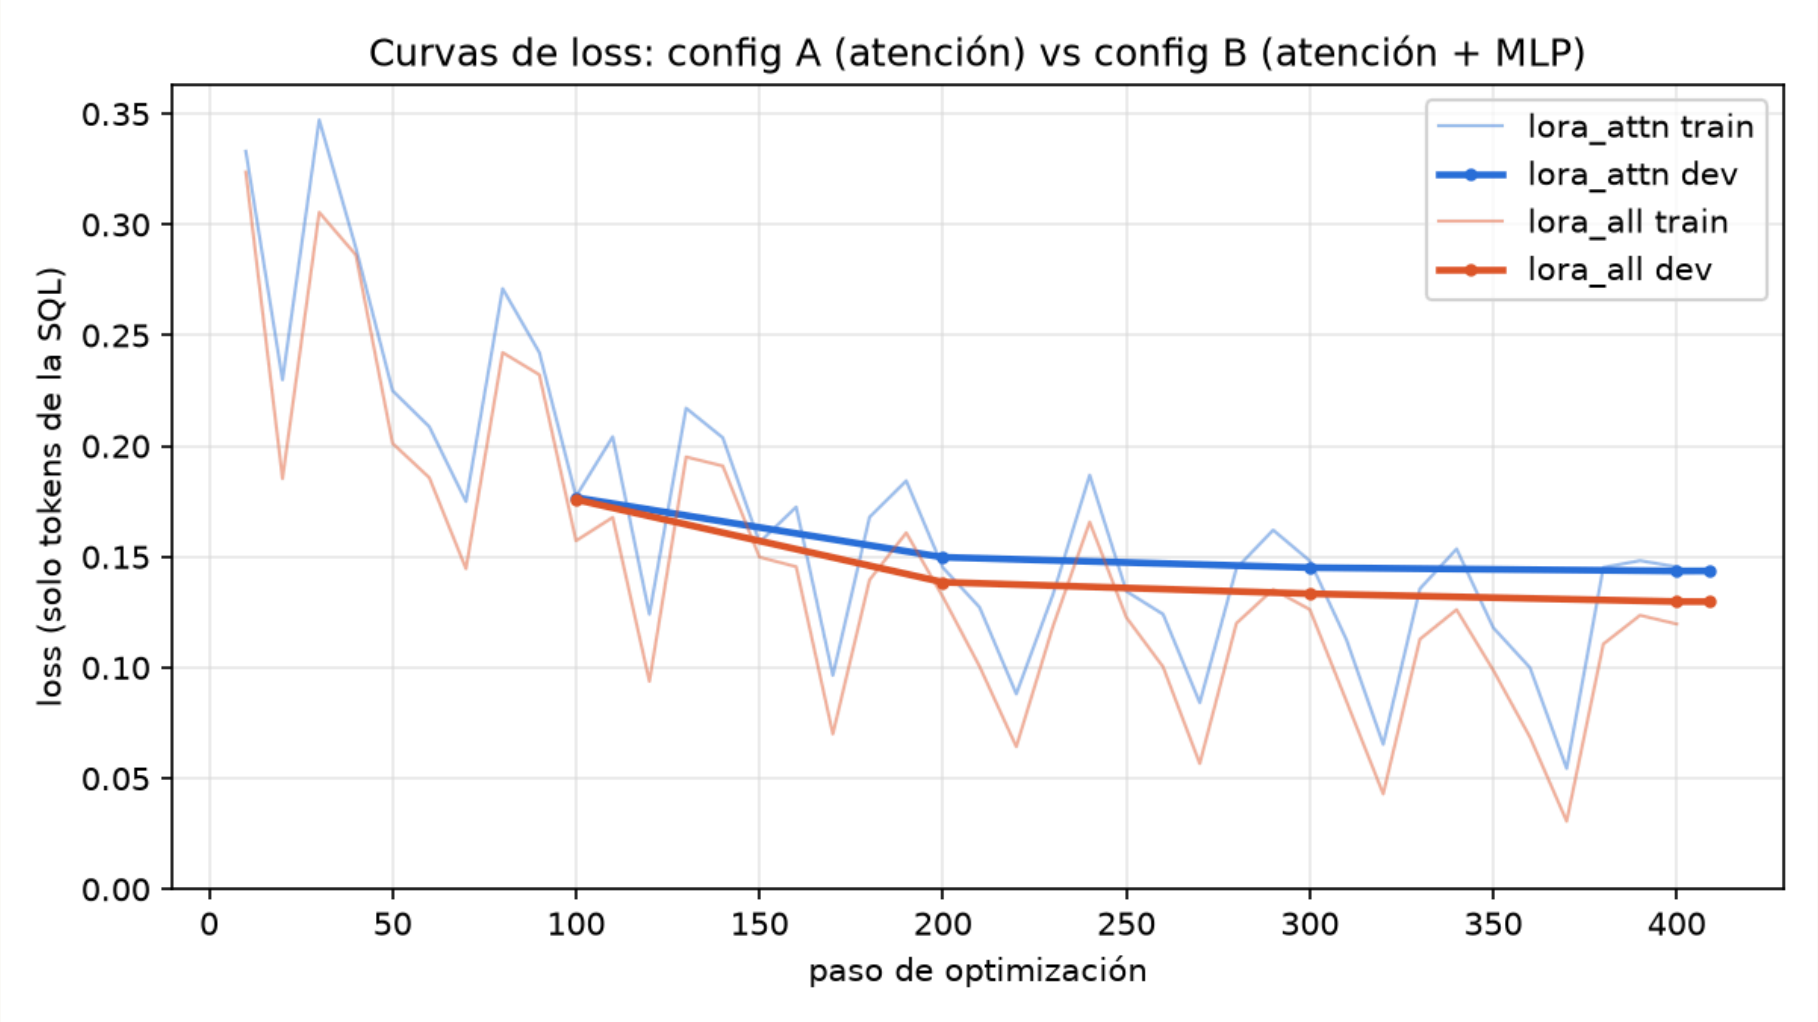
Resultado: confirmada. A arregla las fáciles (7→10/12); B además las medias (6→10/16).

Comunes: r=16, α=32, lr 2e-4 coseno, batch efectivo 16, 1 época, 6 532 ejemplos.

ENTRENAMIENTO

Curvas de loss

la oscilación de train viene de agrupar por longitud

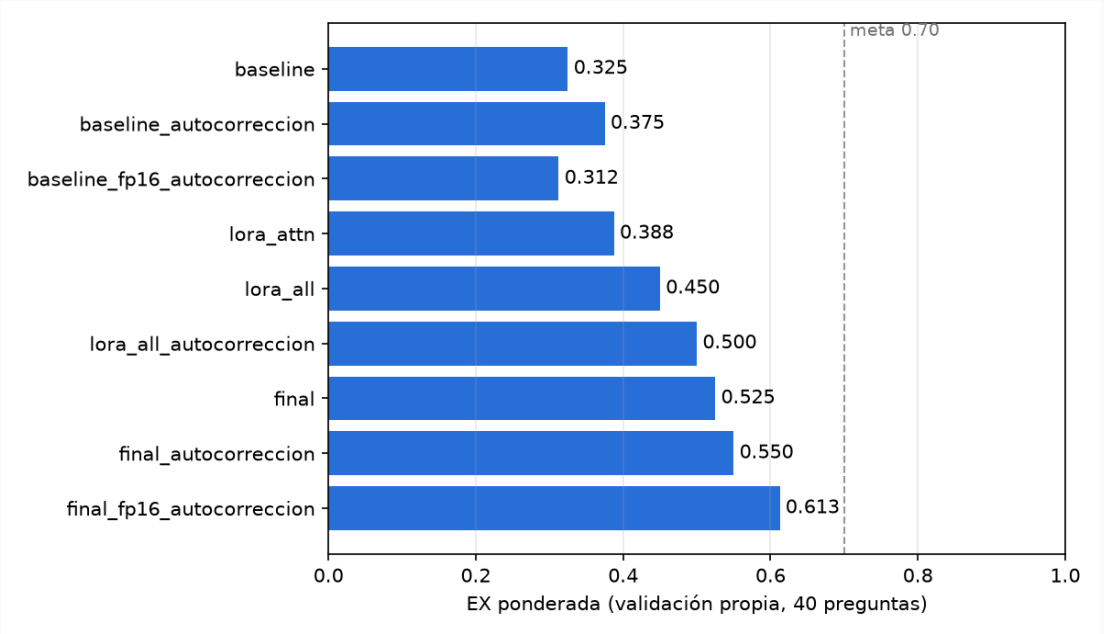


RESULTADOS

Validación propia: 40 preguntas, 2 esquemas no vistos

Modelo	EX	F	M	D
Baseline	0.325	7/12	8/16	1/12
A (atención)	0.388	10/12	6/16	3/12
B (atención+MLP)	0.450	10/12	10/16	2/12
B + autocorrección	0.500	10/12	12/16	2/12
Final	0.525	11/12	11/16	3/12
Final + autocorrección	**0.550**	**11/12**	**12/16**	**3/12**
… en fp16 (T4)	**0.613**	**11/12**	**13/16**	**4/12**

Base + autocorrección: 0.375 (bf16) / 0.313 (fp16) → mejora +0.175 / +0.30



EXPERIMENTO DE INFERENCIA

Autocorrección con `ejecutar`

1. Generar la consulta
2. `ejecutar(sql)` → si hay error, se agrega al diálogo:
   "*La consulta falló en MySQL con este error: … Corrígela*"
3. Regenerar (máx. 3 llamadas, tope interno de 22 s)

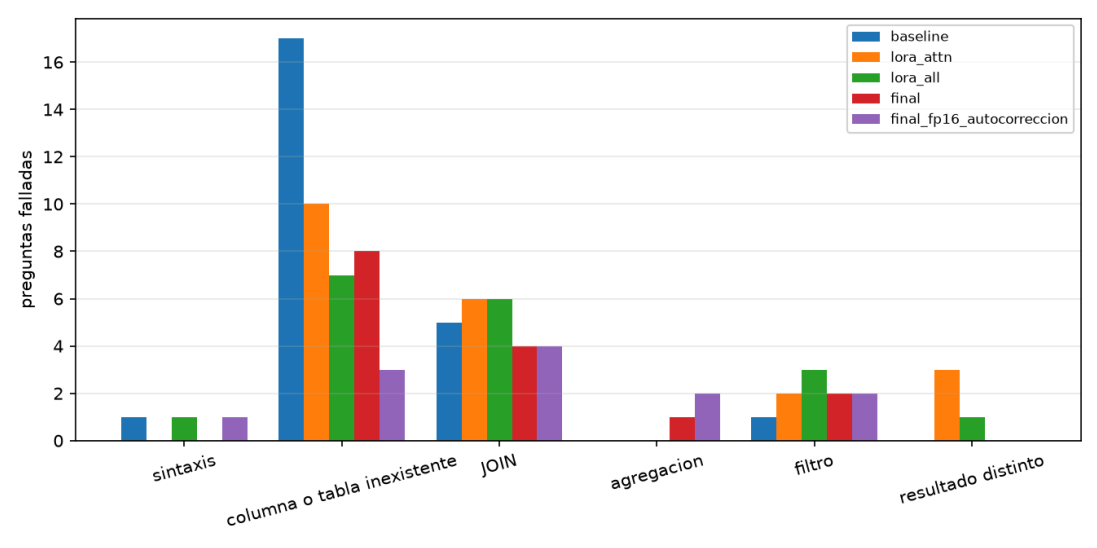
Solo detecta errores de ejecución; no corrige consultas que corren pero responden otra cosa.

	sin	con	Δ
Baseline	0.325	0.375	+0.050
Config B	0.450	0.500	+0.050
Final	**0.525**	**0.550**	**+0.025**

Columna inexistente final: 8 → 4 · ejecutan 32 → 35 · 3.1 s prom., 18.1 s máx. (< 30 s)

ANÁLISIS DE ERRORES

¿En qué se equivoca?

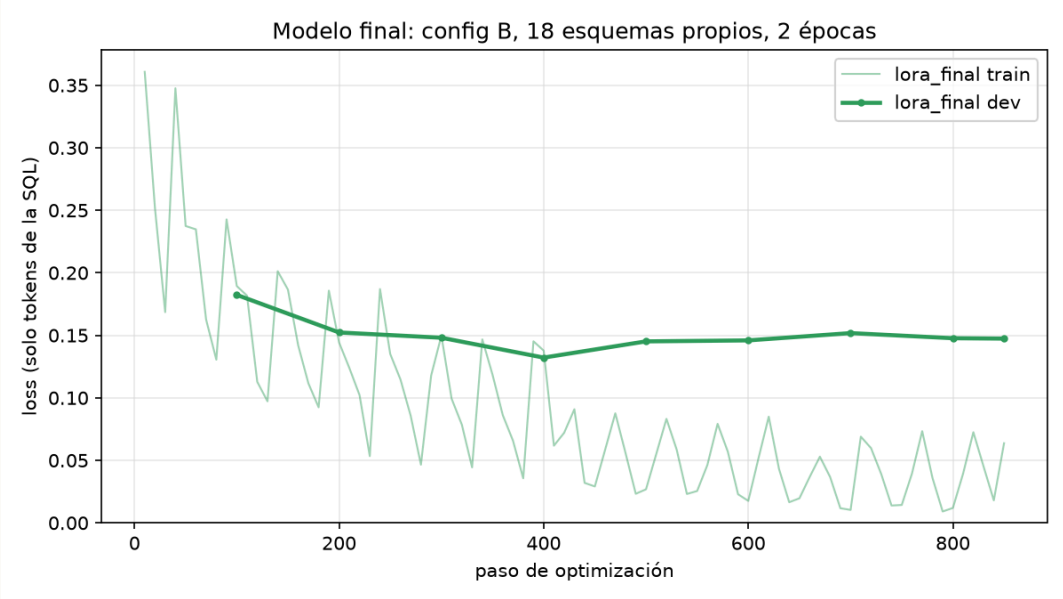


- **Columna inexistente** (baseline 17): inventa `t.att_first_name`; el fine-tuning y la autocorrección lo bajan a 3–4
- **Agregación en dos niveles**: `SUM(x + SUM(y))`, olvida comparar con el promedio del grupo
- **JOIN**: la columna está a 2–3 saltos (cliente → vehículo → orden) y toma un atajo
- **COUNT(*) con LEFT JOIN**: cuenta 1 donde debía ser 0
- **Filtro**: "taller (workshop)" → `'talk'`; omite `IS NOT NULL`
- **Difíciles** (3–4/12): combinar agregaciones de tablas distintas sigue fuera del alcance de 1.5B

MODELO FINAL

Datos dirigidos a los errores + 2 épocas

- 6 esquemas nuevos (veterinaria, gimnasio, inmobiliaria, logística, cine, proyectos de software), 486 pares
- ~40 % difíciles: JOIN de 3–4 tablas, misma tabla unida dos veces, LEFT JOIN con `COUNT(col)`, pre-agregación de detalle
- Config B (atención + MLP), 2 épocas: la loss de dev de B seguía bajando



EX 0.450 → **0.525** (sin autocorrección) · JOIN 6 → 4 · difíciles 2 → 3. La loss de dev toca su mínimo en la época 1 (0.132) y sube a 0.147: hay algo de sobreajuste de estilo, pero la EX (que acepta consultas equivalentes) mejora, así que entregamos el de 2 épocas.

PREDICCIÓN

EX esperada en la evaluación oculta

≈ 0.55

con adapter · intervalo 0.42–0.68

≈ 0.33

sin adapter → mejora ≈ +0.20

- **Validación que imita el formato oculto:** 0.55 (bf16) / 0.61 (fp16, T4) en esquemas no vistos
- **Por nivel:** fácil 92 %, media 75–80 %, difícil 25–33 %. Con 12/14/10 preguntas → ≈ 0.59; más difíciles → ≈ 0.50
- **Ruido:** bf16 frente a fp16 cambia 6 puntos solo por redondeo → error estándar ≈ 0.08
- **Sesgos:** nuestras trampas pueden ser más duras (+); validación y entrenamiento escritos con estilo parecido (−)
- **Mejora estable:** +0.125 / +0.175 / +0.30 en todas las condiciones → esperamos superar +0.15

CIERRE

Lecciones

- **Validar ejecutando, no confiando:** 865 pares descartados; el 47 % corría en MySQL pero respondía otra cosa
- **Datos dirigidos a los errores:** 486 pares sobre los patrones fallidos + una 2.ª época: EX 0.45 → 0.525 (sin separar ambos efectos)
- **LoRA en MLP** rinde más que solo en atención, a cambio de 4× parámetros (que siguen siendo < 1.2 %)
- **8 GB de VRAM:** batch 1 + logits solo para la respuesta: de 117 s a 11 s por paso (sin desbordar a RAM)
- **Límite actual:** razonamiento de varios pasos (JOIN lejanos, agregaciones combinadas) en un modelo de 1.5B

Uso de IA: Claude Code como asistente de código, generación de pares sobre esquemas propios y redacción (detalle en README). Inferencia: solo Qwen2.5-Coder-1.5B + adapter.